

Synthèse

Projets finaux

Bloc 1 > « Plan your trip »

Bloc 2 > « Speed dating »

Bloc 3 > « Walmart sales »

Bloc 4 > « Détecteur spams »

Bloc 5 > « Get around »

Bloc 1 – « Plan your trip »

Construction et alimentation d'une infrastructure de gestion de données

- Objectifs
 - Concevoir une architecture de données robuste et adaptée
 - Intégrer la dimension de stockage et de calcul distribuée à l'infrastructure de données
 - Collecter des données provenant de différentes sources
 - Nettoyer et organiser les données dans l'entrepôt de données

Pipeline de traitement

Collecte des données de localisation (géocodage Nominatim)



Collecte des données météo (OpenWeather API)



Collecte des données hôtels (Booking.com)



Fusion des données et chargement dans un S3 (datalake)




Conversion des données en table SQL (RDS)



Création de cartes interactives




Collecte des données



Utilisation des données

Génération de cartes,

- Sur la base du score météo
- Score météo à 7 jours (/100)
- Focus sur le top 5 villes où aller
- De ces 5 villes, top hôtels
- Les données s'actualisent à chaque lancement de la pipeline



Bloc 2 – « Speed dating »

Analyse exploratoire, descriptive et inférentielle de données

- Objectifs
 - Traiter des bases de données grâce à des analyses statistiques descriptives et inférentielles
 - Effectuer des analyses univariées et multivariées
 - Optimiser les analyses statistiques
 - Présenter le résultat d'une analyse statistique de données structurées

Pipeline d'analyse

Contexte et méthode



Import et lecture du dataset



Nettoyage et exploration des données



Description des participants



Attributs recherchés par les participants




Facteurs influençant la décision finale




Conclusion et perspectives



Description des participants



Facteurs de décision



Résultats

- 8378 entretiens réalisés auprès de 551 participants
- 16% des speed dating réalisés ont trouvé un 'match' (soit, 15% des participants)
- Les critères recherchés ne sont pas nécessairement les critères de sélection pour valider une décision → Rappelons que les participants sont d'abord présents car ils recherchent un lien social et sont là pour 's'amuser'

Bloc 3 – « Walmart Sales »

Analyse prédictive de données structurées par l'intelligence artificielle

- Objectifs
 - Traiter des données structurées en créant un pipeline de traitement
 - Effectuer des analyses prédictives sur un jeu de données structurées
 - Élaborer un algorithme d'apprentissage automatique
 - Évaluer la performance prédictive des algorithmes d'apprentissage automatique

Pipeline de traitement

Import des données

↓

Analyse exploratoire (EDA) et statistiques descriptives

↓

Prétraitement des données (gestion des NaN, conversion des dates, suppression des outliers)

↓

Création d'un modèle de régression linéaire de référence

↓

Évaluation et interprétation des coefficients du modèle

↓

Amélioration du modèle avec régularisation (Ridge, Lasso) et optimisation des hyperparamètres

↓


Normalisation des ventes par magasin pour analyser l'influence économique pure

↓

Analyse finale des performances et des variables influentes




Analyses



Algorithme

Objectif de l'algorithme : prédire le montant des ventes hebdomadaires des magasins



Performances

Avec variable « Store_ID »

Sans variable « Store_ID »

Modèle de régression linéaire ajusté (Modèle de Ridge)

$R^2 = 95 \%$

La variance est expliquée à 95% par le
modèle de prédiction
Effet magasin ++

$R^2 = 22 \%$

La variance est expliquée à 22% par le
modèle de prédiction
Les variables économiques ont un effet
modéré sur les prédictions des ventes

Bloc 4 – « Détecteur spam »

Analyse prédictive de données non-structurées par l'intelligence artificielle

- Objectifs
 - Traiter des données non-structurées
 - Élaborer des réseaux de neurones adaptés
 - Créer un algorithme robuste et précis
 - Créer des données non-structurées en élaborant des réseaux de neurones adverses
 - Évaluer la performance d'un algorithme d'apprentissage automatique profond

Pipeline de traitement

```
Import et nettoyage des données
↓
Exploration et analyse descriptive
↓
Prétraitement des données
↓
Création d'un modèle de classification (LogisticRegression)
↓
Évaluation du modèle
↓
Création d'un modèle d'apprentissage profond (CNN)
↓
Évaluation du modèle
↓
Application d'un modèle d'apprentissage par transfert(HuggingFace)
↓
Evaluation du modèle et comparaisons avec les autres modèles
```



Traitement


- Identifier ce qui différencie un spam d'un ham




Longueur des
messages

Analyse des
tokens

Algorithmes



Performances apprentissage par transfert



Bloc 5 – « Get Around »

Industrialisation d'un algorithme d'apprentissage automatique et automatisatisation des processus de décision


- Objectifs
 - Standardiser la construction et l'environnement informatique d'un algorithme d'apprentissage automatique
 - Créer une interface de programmation applicative
 - Déployer une application web intégrant des algorithmes de statistiques prédictives

Pipeline de traitement

```
Importation des données
↓
Analyse exploratoire (EDA)
↓
Prétraitement (nettoyage, dates, outliers)
↓
Entraînement d'un modèle CatBoost
↓
Évaluation et interprétation
↓
Enregistrement du modèle avec MLflow
↓
Déploiement du modèle de prédiction (FastApi)
↓
Mise à disposition des analyses et du modèle de prédiction (Streamlit)
↓
Déploiement du modèle, API de prédiction et dashborad (Docker)
```



Interface de programmation Streamlit



Déploiement du modèle de prédiction

Application Streamlit lancée avec succès

Vérification des données

data/get_around_pricing_project.csv trouvé

data/get_around_delay_analysis.xlsx trouvé

Navigation

- ☐ Accueil
- ☐ Analyse des données GetAround
- ☒ Estimation du prix de location

🔗 Analyse des retards et estimation de prix des locations

🔗 Estimation du prix de location

Modèle
Citroën

Carburant
electrique

Couleur
blue

Type
estate

Kilométrage
60000

Puissance moteur
50

☐ GPS

☐ Climatisation

☒ Automatique

Estimer le prix de la location

2 Envoi d'un requête POST au endpoint /predict

Prix estimé : 106.87 € / jour

Fourchette : 96.18 € - 117.55 €

1 Création d'une requête de prédiction

3 Réponse de l'API après consultation du modèle

4 Suivi des métriques du modèle

Standardisation de l'environnement

