

Synthèse

Projets finaux

Bloc 1 > « Plan your trip »

Bloc 2 > « Speed dating »

Bloc 3 > « Walmart sales »

Bloc 4 > « Détecteur spams »

Bloc 5 > « Get around »

Bloc 1 – « Plan your trip »

Construction et alimentation d'une infrastructure de gestion de données

- Ce projet vise à créer une application de recommandation de destinations en France en se basant sur des données réelles de localisation, météo et hôtels.

Pipeline de traitement

Collecte des données de localisation (géocodage Nominatim)



Collecte des données météo (OpenWeather API)



Collecte des données hôtels (Booking.com)



Fusion des données et chargement dans un S3 (datalake)



Conversion des données en table SQL (RDS)




Création de cartes interactives

1

2




Collecte des données



Utilisation des données

Génération de cartes,

- Sur la base du score météo
- Focus sur le top 5 villes où aller
- De ces 5 villes, top hôtels
- Les données s'actualisent à chaque lancement de la pipeline



Pistes évolutions

1

Authentication client

2

Quotas API

3

Fiabilisation scraping

Bloc 2 – « Speed dating »

Analyse exploratoire, descriptive et inférentielle de données

- Ce projet vise à analyser un jeu de données issu d'expériences de speed dating menées entre 2002 et 2004.
- L'objectif est de comprendre quels facteurs influencent l'intérêt mutuel entre deux personnes et quels attributs motivent la décision d'un second rendez-vous

Jeu de données



8 000 rencontres

550 participants

195 variables

Pipeline d'analyse

Contexte et méthode



Import et lecture du dataset



Nettoyage et exploration des données



Description des participants



Attributs recherchés par les participants



Facteurs influençant la décision finale




Conclusion et perspectives



Description des participants



- Age : 26 ans
- Autant d'hommes que de femmes
- Intérêts : films, musiques, dîner
- 1 participant sur 2 participe à des dates deux fois par mois ou plusieurs fois dans l'année
- La religion ou l'origine ethnique ne sont pas des critères pour un participant sur 2.

Description des participants



- « faire des rencontres » plutôt que de « rencontrer quelqu'un »

Facteurs de décision



Conclusion

- Les critères recherchés ne sont pas nécessairement les critères de sélection pour valider une décision → Rappelons que les participants sont d'abord présents car ils recherchent un lien social et sont là pour 's'amuser'

Pistes évolutions

1

Prédire la réussite d'un match

Bloc 3 – « Walmart Sales »

Analyse prédictive de données structurées par l'intelligence artificielle

- L'objectif de ce projet est de comprendre et de modéliser l'influence des indicateurs économiques et autres facteurs sur les ventes hebdomadaires des magasins Walmart.

Pipeline de traitement

Import des données

↓

Analyse exploratoire (EDA) et statistiques descriptives

↓

Prétraitement des données (gestion des NaN, conversion des dates, suppression des outliers)

↓

Création d'un modèle de régression linéaire de référence

↓

Évaluation et interprétation des coefficients du modèle

↓

Amélioration du modèle avec régularisation (Ridge, Lasso) et optimisation des hyperparamètres

↓



Normalisation des ventes par magasin pour analyser l'influence économique pure

↓


Analyse finale des performances et des variables influentes



Analyse exploratoire




Analyse macro



Algorithme

Objectif de l'algorithme : prédire le montant des ventes hebdomadaires des magasins



Régression
linéaire

Performances

Avec variable « Store_ID »


Modèle de régression linéaire

$R^2 = > 95 \%$
RMSE test > RMSE train
Effet magasin ++


```
=== Top coefficients (LinearRegression) ===  
      Feature      Coefficient  
10    Store_4.0    2513942.31  
18    Store_13.0   2258526.19  
16    Store_10.0   2200587.44  
24    Store_19.0   1561012.50  
11    Store_5.0    -1280097.27  
9     Store_3.0    -1279595.86  
23    Store_18.0   1206172.22  
15    Store_9.0    -1191550.72  
19    Store_14.0   1158976.20  
22    Store_17.0   952718.46
```

Algorithme

Objectif de l'algorithme : prédire le montant des ventes hebdomadaires des magasins




Performances



Algorithme

Objectif de l'algorithme : prédire le montant des ventes hebdomadaires des magasins



Performances

Sans variable « Store_ID »

Modèle de régression linéaire (Modèle de Ridge)

$R^2 = 14 \%$ jeu test
Les variables économiques ont un effet modéré
sur les prédictions des ventes

Top coefficients économiques :

	Feature	Coefficient
8	Holiday_Flag_1.0	-94155.62
1	Fuel_Price	-50186.78
6	Day	-37697.13
4	Year	33151.92
0	Temperature_C	-28518.87
5	Month	26385.92
3	Unemployment	-1216.72
2	CPI	84.23
7	Weekday	0.00

Pistes évolutions

1

Ajout de variables structurelles

2

Augmenter la taille de l'échantillon

Bloc 4 – « Détecteur spam »

Analyse prédictive de données non-structurées par l'intelligence artificielle

- Le projet consiste à identifier les **messages SPAMS** reçus par sms pour en automatiser la détection.


Pipeline de traitement

```
Import et nettoyage des données
↓
Exploration et analyse descriptive
↓
Prétraitement des données
↓
Création d'un modèle de classification (LogisticRegression)
↓
Évaluation du modèle
↓
Création d'un modèle d'apprentissage profond (CNN)
↓
Évaluation du modèle
↓
Application d'un modèle d'apprentissage par transfert(HuggingFace)
↓
Evaluation du modèle et comparaisons avec les autres modèles
```



Exploration et analyse



- Identifier ce qui différencie un spam d'un ham



Typologie des
messages


Contenu des
messages

Exploration et analyse



Exploration et analyse

- Identifier ce qui différencie un spam d'un ham



Typologie des
messages

Contenu des
messages

Analyse des tokens


Top tokens (ham):

	token	tfidf_sum
4115	num	75.19
4453	ok	71.85
3312	ll	53.20
2969	just	46.98
2393	gt	45.47
1108	come	44.81
3484	lt	44.65
3070	know	44.03
3243	like	43.26
2315	got	42.68
3486	lt gt	40.64
2283	good	39.88
6225	time	39.43
2661	home	39.17
5715	sorry	38.20
2260	going	37.82
3393	lor	35.81
1353	da	35.80
6810	want	35.78
3143	later	35.57

Top tokens (spam):

	token	tfidf_sum
4115	num	90.86
4642	phone	40.39
2049	free	22.08
4273	num num	19.61
6432	txt	15.97
6618	url	13.99
5842	stop	13.65
1023	claim	13.21
3782	mobile	12.80
6089	text	12.60
6551	ur	12.30
5167	reply	12.07
4919	prize	10.86
5471	service	9.74
903	cash	9.46
7035	won	9.41
4026	new	8.84
6603	urgent	8.59
29	150p	8.31
4078	nokia	7.63

Algorithmes



Logistic
Regression


Résultats

- Recall spam $\approx 95\%$ $\rightarrow$ très peu de spams manqués
(les spams sont effectivement des spams)
- Precision spam $\approx 82\%$ $\rightarrow$ quelques faux positifs
(ham en réalité des spams)
- ROC-AUC ≈ 0.99 $\rightarrow$ très bonne séparation des classes

Recall $\rightarrow$ capacité à détecter les vrais positifs

Precision $\rightarrow$ qualité des prédictions positives


Algorithmes




Résultats

- Recall spam $\approx 99\%$ $\rightarrow$ Presque tous les spams sont détectés
- Precision $\approx 97\%$ $\rightarrow$ peu de faux positifs
- ROC-AUC ≈ 0.994

Algorithmes



Résultats



ROC-AUC: 1.00

Pistes évolutions

1

Choix du modèle

2

Mise en production

Bloc 5 – « Get Around »

Industrialisation d'un algorithme d'apprentissage automatique et automatisatisation des processus de décision

- Objectifs
 - Standardiser la construction et l'environnement informatique d'un algorithme d'apprentissage automatique
 - Créer une interface de programmation applicative
 - Déployer une application web intégrant des algorithmes de statistiques prédictives

Problématiques identifiées

- Gestion des retards
- Estimation du prix de la location

Pipeline de traitement



Importation des données

↓

Analyse exploratoire (EDA)

↓

Prétraitement (nettoyage, dates, outliers)

↓

Entraînement d'un modèle CatBoost

↓

Évaluation et interprétation

↓

Enregistrement du modèle avec MLflow

↓

Déploiement du modèle de prédiction (FastApi)

↓

Mise à disposition des analyses et du modèle de prédiction (Streamlit)

↓

Déploiement du modèle, API de prédiction et dashborad (Docker)

1

2

Modélisation et suivi des expériences


3

Mise en production

Choix et résultat du modèle

- Modèle CatBoost
- Résultats du modèle
- $R^2 = 82\%$ → proportion de variance expliquée par le modèle
- RMSE = 14 € → le modèle se trompe en moyenne de +/- 14.19 € sur le prix prédit

Interface de programmation Streamlit



Déploiement du modèle de prédiction

Application Streamlit lancée avec succès

Vérification des données

data/get_around_pricing_project.csv trouvé

data/get_around_delay_analysis.xlsx trouvé

Navigation

- ☐ Accueil
- ☐ Analyse des données GetAround
- ☒ Estimation du prix de location

🔗 Analyse des retards et estimation de prix des locations

🔗 Estimation du prix de location

Modèle
Citroën

Carburant
electrique

Couleur
blue

Type
estate

Kilométrage
60000

Puissance moteur
50

☐ GPS

☐ Climatisation

☒ Automatique

Estimer le prix de la location

2 Envoi d'un requête POST au endpoint /predict

Prix estimé : 106.87 € / jour


Fourchette : 96.18 € - 117.55 €

1 Création d'une requête de prédiction

3 Réponse de l'API après consultation du modèle

4 Suivi des métriques du modèle

Standardisation de l'environnement



Pistes évolutions

1

Docker Compose

2

Monitoring

2

Gestion des écarts des données